

Justificativa

Justifica-se este trabalho pois a poluição plástica em ambientes aquáticos é um dos grandes problemas ecológicos que o planeta enfrenta hoje em dia. De acordo com Mundo, dados da ONU de março de 2023 mostram que entram nos ecossistemas aquáticos cerca de 14 milhões de toneladas de resíduos plásticos por ano. Todos os dias, portanto, são despejadas altas quantidades de lixo plástico em rios, lagos e oceanos. A lenta decomposição desses na água geram os microplásticos, que afetam diretamente a qualidade da água. A identificação rápida dessa poluição é de extrema importância para que sua remoção seja feita antes que os impactos na água e no meio ambiente sejam maiores.

Embora existam medidas de patrulha realizadas pelo governo, pela marinha e por ONGs para tentar resolver esse problema, faltam métodos que automatizem e facilitem o monitoramento eficiente dessas áreas, tanto para fins de proteção ambiental quanto para o levantamento de dados geoambientais.

Problema

Como desenvolver um software baseado em inteligência artificial e treiná-lo para que detecte e localize resíduos plásticos em imagens de ambientes aquáticos?

Objetivo

Desenvolver e treinar um software baseado em inteligência artificial com a capacidade de detectar e localizar resíduos plásticos em imagens de ambientes aquáticos.

Referencial Teórico

Treinamento de máquina

O treinamento de máquina é uma área da inteligência artificial que tem o objetivo de ensinar ao software a identificação de padrões e a tomada de decisões com base nesses padrões. Isso se torna muito vantajoso para resolver problemas em que não temos um algoritmo bem definido, como nos processos de identificação (TANAKA, 2018).

Aprendizado supervisionado

Método de treinamento que se baseia em dizer a máquina qual a classificação das entradas, para que ela aprenda quais características definem as classes (TANAKA, 2018).

MobileNetV2

O MobileNetV2 é uma arquitetura de rede neural convolucional projetada para ser leve e eficiente, tornando-se uma escolha popular para tarefas de detecção de objetos e classificação de imagens.

Otimizador "ADAM"

O "ADAM" (Estimativa de Momento Adaptável) é um método de otimização onde os gradientes das previsões em relação aos pesos são calculados e usados para atualizar os pesos de forma incremental. Os pesos de uma rede neural determinam o impacto que o valor de cada variável de entrada tem no valor das variáveis de saída.



SDPPA

Software para Detecção de Poluição Plástica na Água

Pesquisadores: Arthur Padilha, Augusto Schneider e Bernardo Rodrigues

Orientadora: Francine Numer

Biblioteca TensorFlow

TensorFlow é uma biblioteca de código aberto para aprendizado de máquina, que foi utilizada no projeto. Ela oferece uma variedade de funções e recursos que permitem a criação, treinamento e uso eficaz de modelos.

Pré-processamento e segmentação de imagens digitais

O pré-processamento envolve a aplicação de técnicas para aprimorar a eficiência do uso de imagens, enquanto a segmentação identifica e separa regiões de interesse. Ambos envolvem a manipulação dos pixels em imagens digitais. No programa, foram utilizados os recursos da biblioteca de código aberto OpenCV, especializada em processamento de imagens e visão computacional.

Metodologia

Inicialmente, foram criados os bancos de imagens destinados ao treinamento, contendo fotos diversas de resíduos plásticos, e aos testes, retratando ambientes aquáticos submetidos à poluição plástica.

A linguagem de programação escolhida foi Python, todo o desenvolvimento do software e da interface gráfica para visualização das respostas foi feito na IDE Pycharm.

• Treinamento da rede neural

Foi escolhido o modelo MobileNetV2 como arquitetura de rede neural, por conta da sua fácil acessibilidade. Para adaptar a rede ao problema de detecção de poluição plástica, foram adicionadas camadas personalizadas no topo da arquitetura. Sendo elas:

1. Uma camada de Global Average Pooling, para calcular a média global das características extraídas pela rede;
2. Duas camadas densas com ativação ReLU para melhorar a capacidade de aprendizado da rede;
3. Uma camada densa de saída com ativação softmax para produzir as probabilidades associadas a cada classe ("Imagem sem plástico" e "Imagem com plástico").

Durante o treinamento supervisionado, o modelo recebe exemplos de imagens de plásticos e seus rótulos correspondentes. Com base nessas informações, ele calcula as previsões para cada imagem e compara essas previsões com os rótulos reais para medir o quanto próximo ou distante está da resposta correta.

Para melhorar suas previsões, o modelo utiliza o otimi-

zador "ADAM", que ajusta os pesos de suas camadas. A rede neural, portanto, foi treinada para responder se a entrada é um resíduo plástico ou não.

• Pré-processamento e segmentação da imagem de previsão

É criada uma cópia da imagem de entrada, que é convertida em tons de cinza e suavizada pelo filtro Gaussian Blur. O resultado é submetido ao algoritmo Canny, que faz a detecção de bordas na imagem.

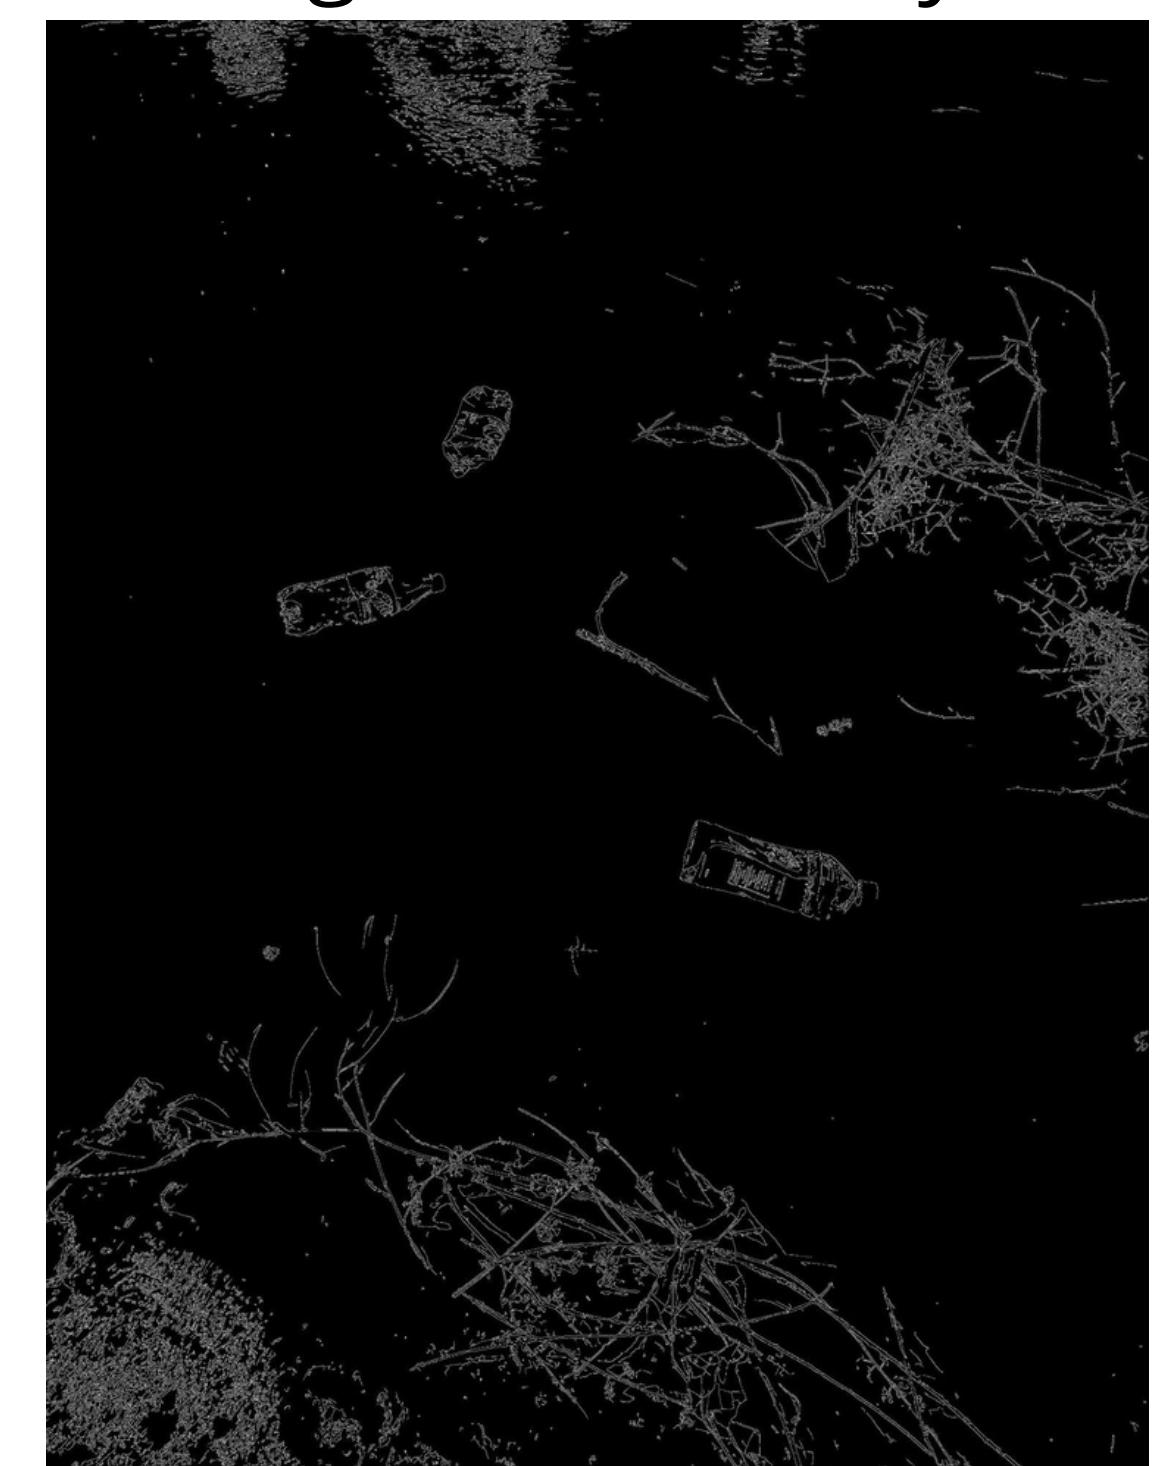
Figura 1 - Imagem original



Figura 2 - cópia suavizada



Figura 3 - Cópia pós algoritmo Canny



Fonte: Os autores (2023).

As bordas detectadas são dilatadas para facilitar seu reconhecimento na etapa de segmentação, que isola os objetos (possíveis resíduos plásticos) do restante da imagem. É desenhada uma caixa delimitadora ao redor de cada objeto detectado, elas são recortadas e salvas em novas imagens, que servirão como entrada para a fase de análise e classificação da rede neural.

Figura 4 - Bordas detectadas

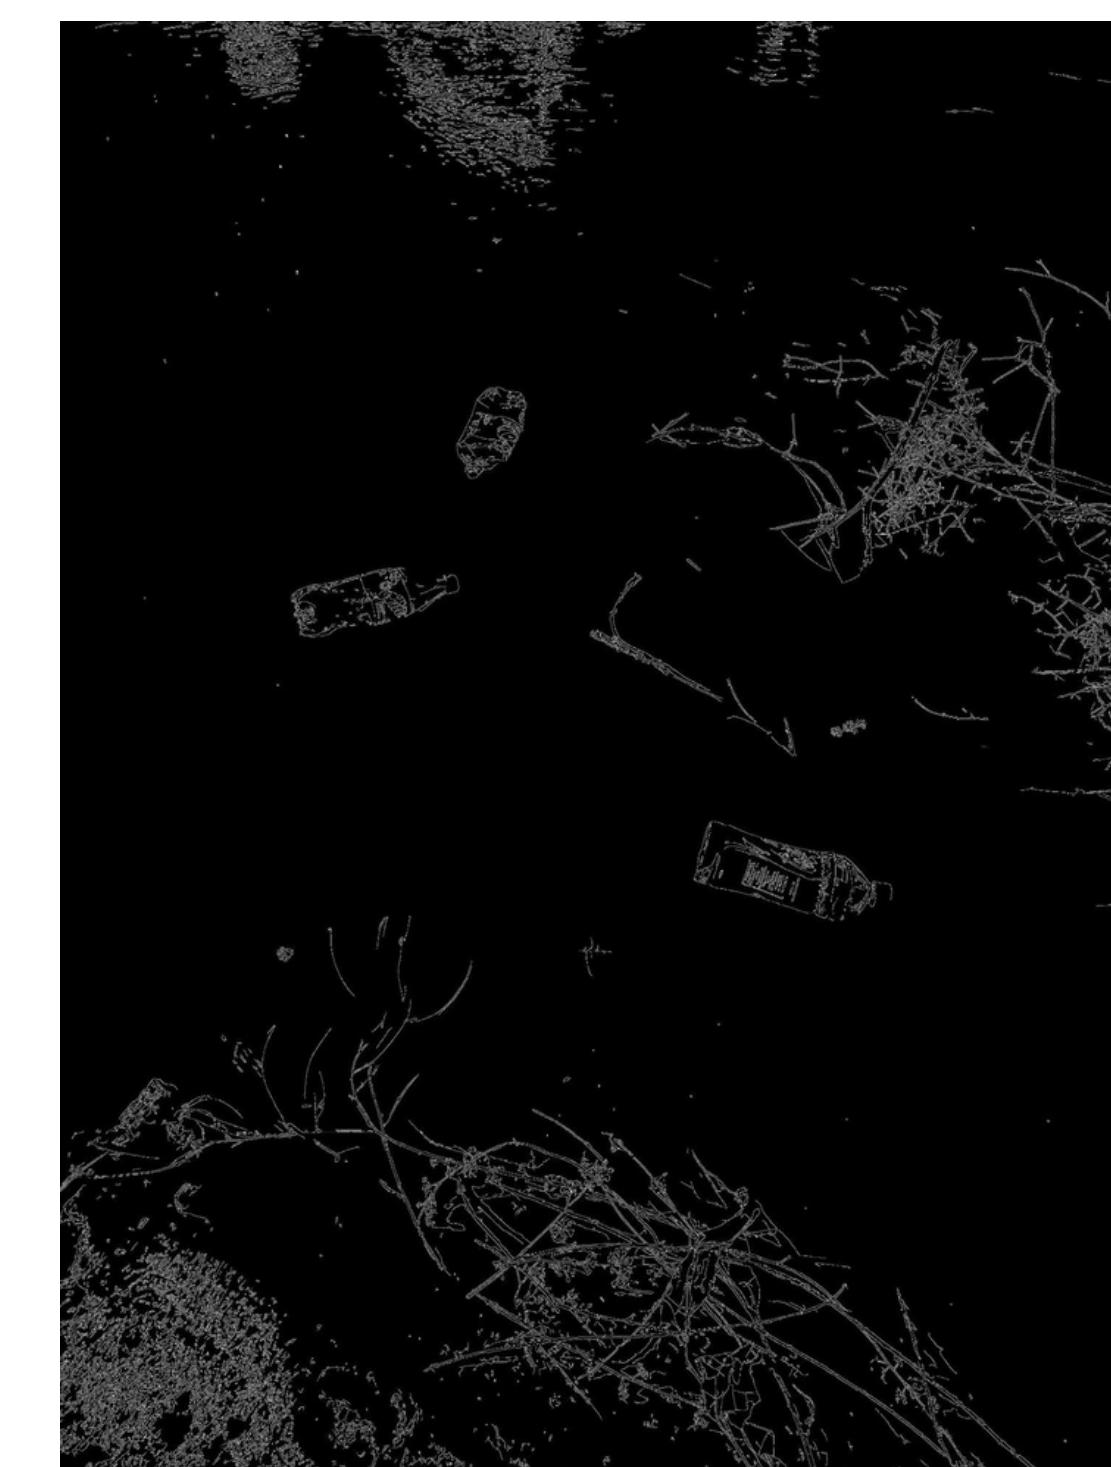


Figura 5 - Dilatação dos contornos

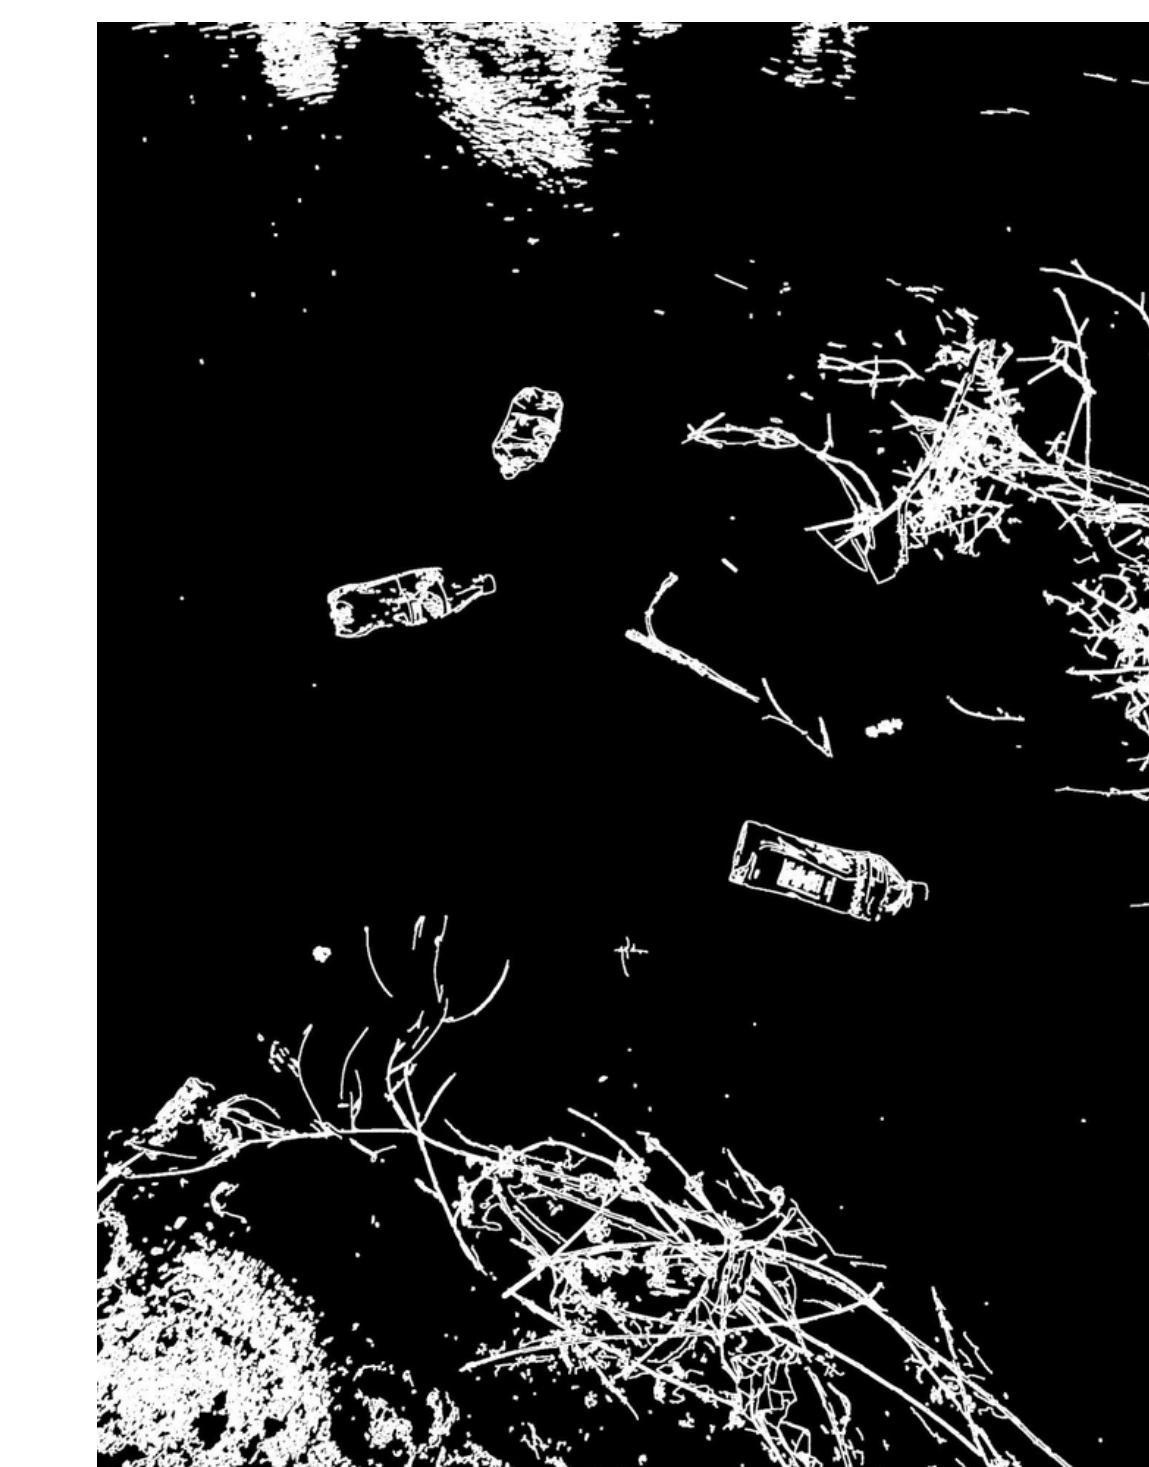
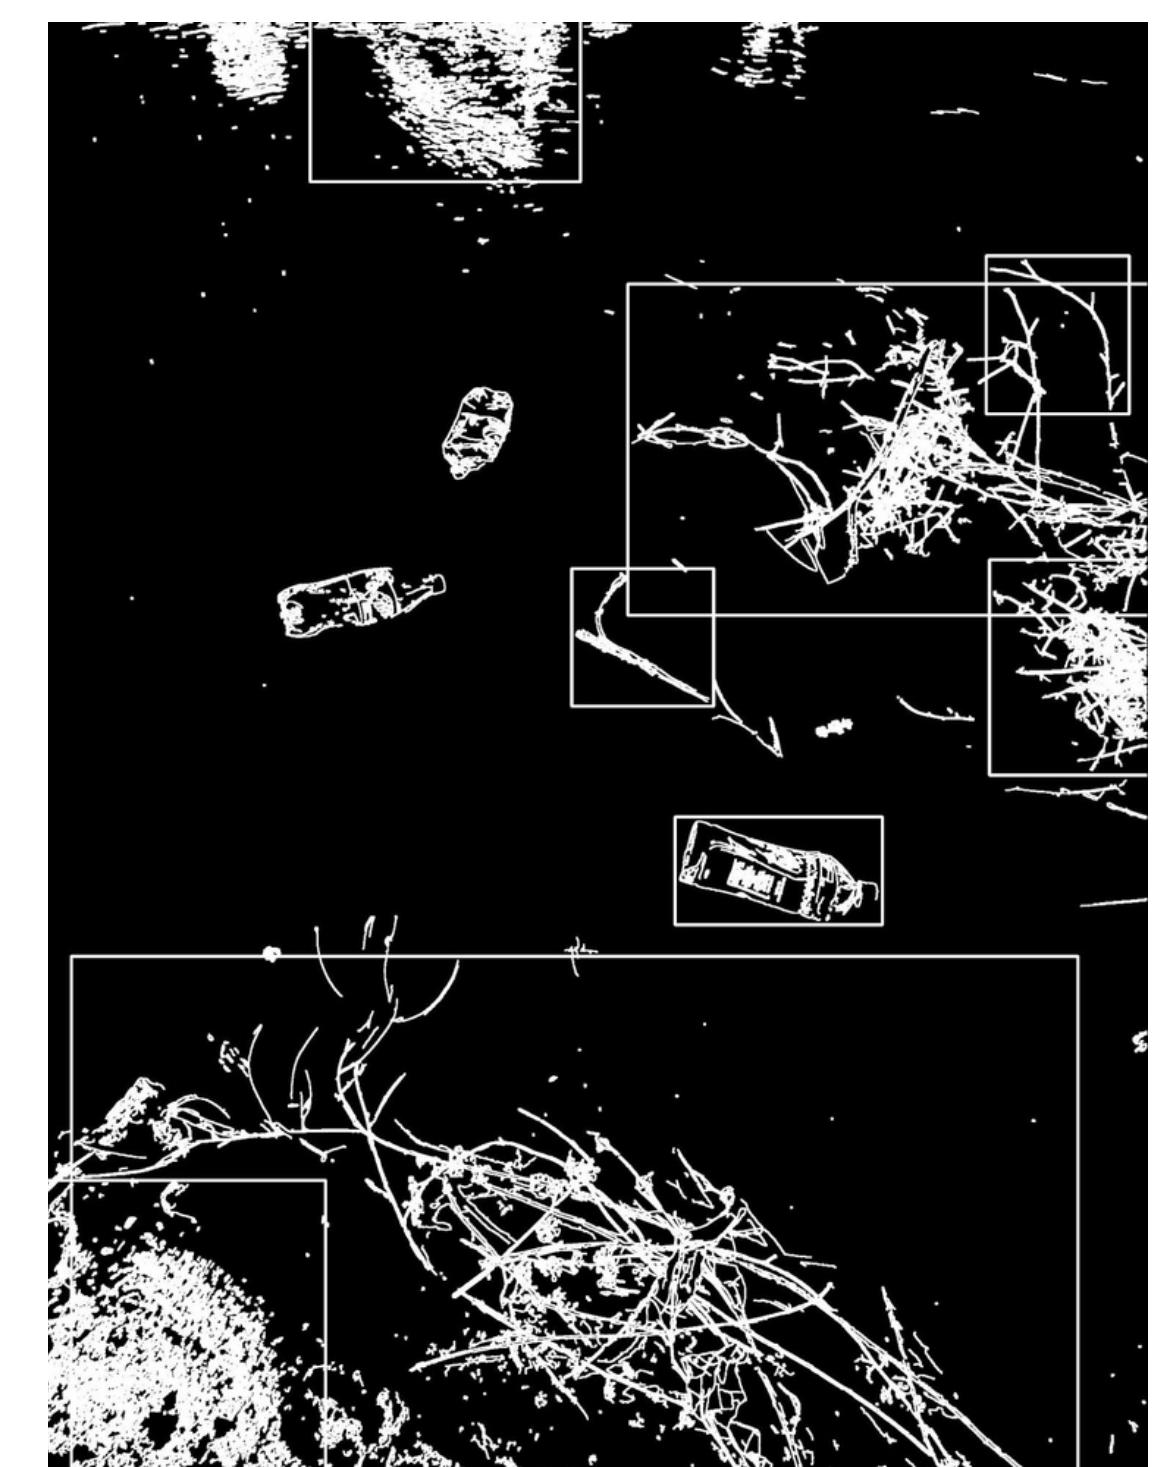


Figura 6 - Segmentação dos objetos



Fonte: Os autores (2023).

Caso a rede neural classifique o objeto como plástico, a caixa que delimita o resíduo é destacada na imagem de saída; caso contrário, a caixa é ignorada. Tornando possível o rastreamento dos resíduos plásticos nas imagens dos ambientes aquáticos.

Análise de Dados

Com os testes finais, usando as imagens do banco de dados para testes, foi observado que o treinamento aplicado ao modelo produziu resultados positivos, pois a rede neural consegue distinguir plásticos de outros objetos presentes nas imagens.

Figura 7 - Resultado satisfatório com um resíduo

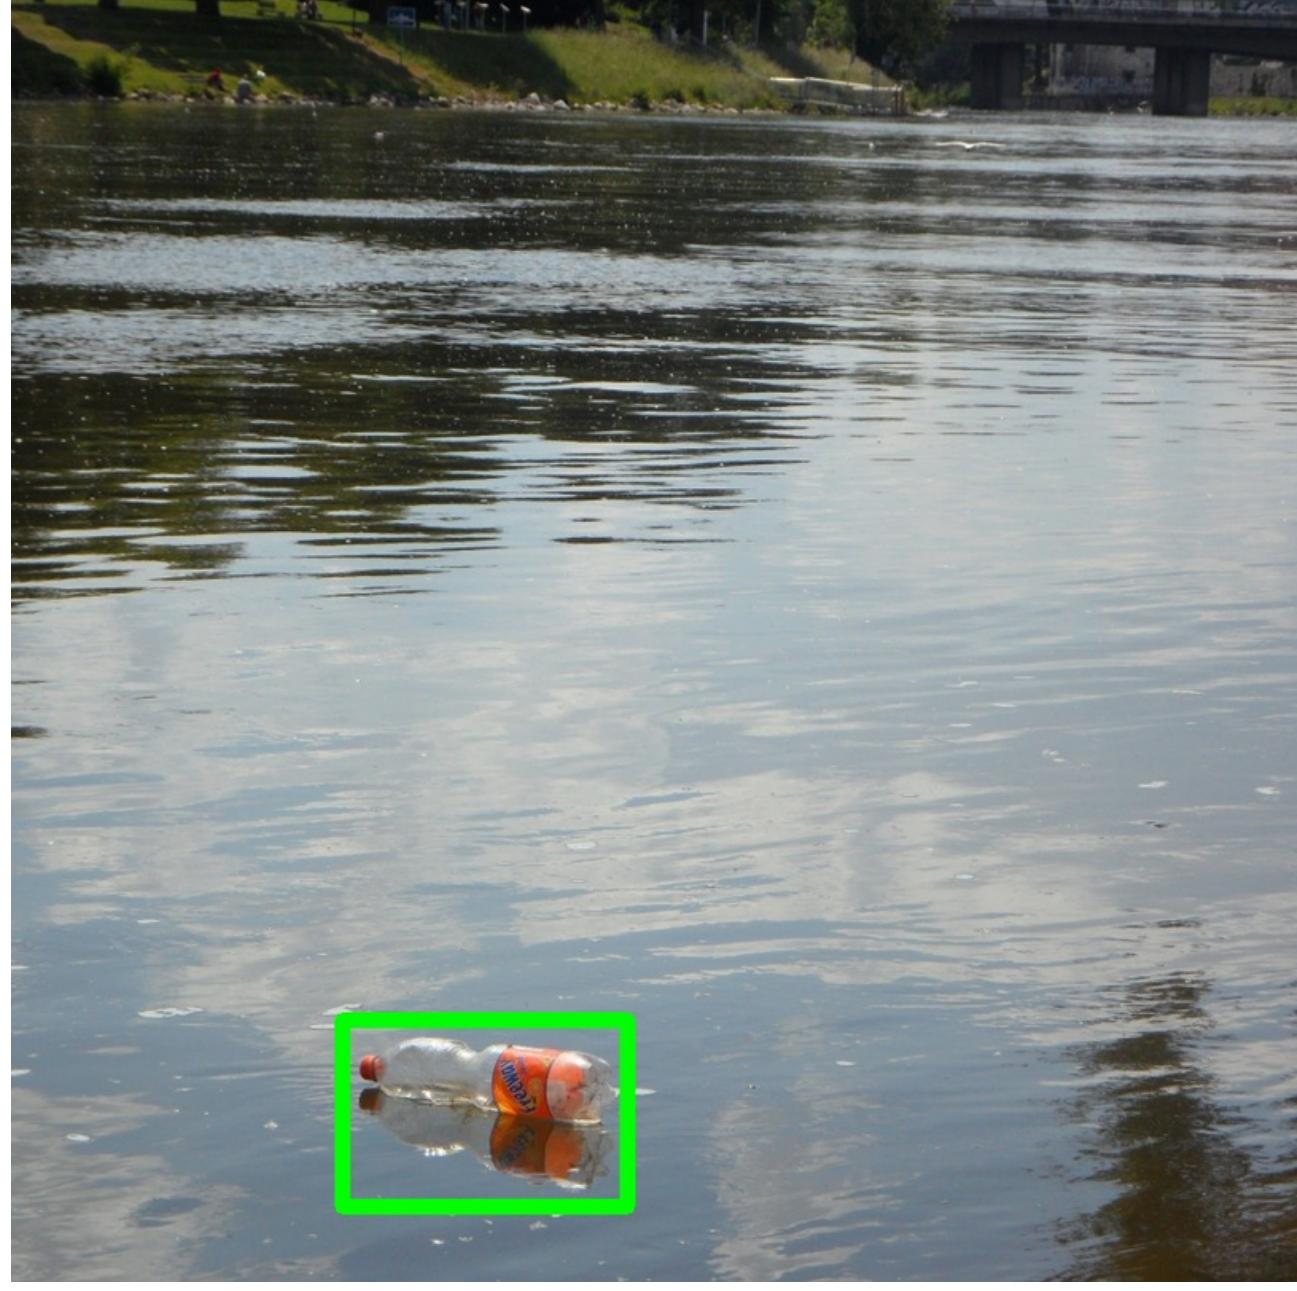


Figura 8 - Resultado satisfatório sem resíduos



Figura 9 - Resultado satisfatório com mais de um resíduo



Fonte: Os autores (2023).

A precisão da resposta final está diretamente vinculada à etapa de pré-processamento. Como podemos observar nos exemplos, quando os resíduos ocupam espaços maiores na imagem a segmentação da imagem é facilitada, resultando em um reconhecimento preciso. Por outro lado, quando um objeto ocupa uma área reduzida na imagem, torna-se mais desafiador para os filtros de borda identificarem o objeto, o que pode resultar na exclusão desses resíduos do processo de análise pela rede neural. Esse é um problema que ocorre ocasionalmente.

Figura 10 - Resultados com resíduos que não foram segmentados



Fonte: Os autores (2023).

É importante ressaltar a falta de imagens noturnas nos bancos de imagens de treinamento e teste. Isso implica que o software não foi treinado para situações em que a iluminação é significativamente mais fraca, o que pode resultar em dificuldades na identificação de resíduos nesse contexto.

Conclusão

Ao término do projeto, concluiu-se que o software é capaz de efetuar a detecção da poluição plástica na água, mostrando que o objetivo do projeto foi alcançado, mesmo diante de suas pequenas falhas, que realçam a necessidade de futuros aprimoramentos. Além dessas melhorias, é de interesse do grupo realizar a adaptação do software para operar em tempo real, permitindo sua integração em sistemas de monitoramento de ambientes aquáticos, tanto diurnos quanto noturnos.

Referências

- GONZALEZ, Rafael; WOODS, Richard. **Processamento de imagens digitais**. São Paulo: Blucher, 2000.
- LEITE, João. **Introdução à imagem digital**. São Paulo. Disponível em: <<https://www.avmakers.com.br/blog/introducao-a-imagem-digital>> Acesso em: 13 jun. 2023.
- MUNDO joga um caminhão de lixo, por minuto, nos oceanos. **ONU News**. Nova Iorque, 30 mar. 2023. Disponível em: <<https://news.un.org/pt/story/2023/03/1812152>> Acesso em: 30 jun. 2023.
- TANAKA, Marcos. **O que é Machine Learning e como funciona**. Maringá. Disponível em: <<https://imasters.com.br/back-end/o-que-e-machine-learning-e-como-funciona>> Acesso em: 27 jul. 2023.